



# TOÁN CHO KHOA HỌC MÁY TÍNH

## HỒI QUY SOFTMAX

TS. Lương Ngọc Hoàng



# Nội dung

1. Giới thiệu hồi quy softmax
2. Hàm mất mát & Tính toán gradient
3. Cài đặt & Phân tích hồi quy softmax



# HỒI QUY SOFTMAX

## SOFTMAX REGRESSION




# Bài toán phân lớp

Bài toán phân lớp (classification):

Với mỗi điểm dữ liệu đầu vào  $x = (x_1, x_2)$ , ta muốn đầu ra của mô hình **dự đoán nhãn (label)** của  $x$  là **nhãn 0 (lớp đỏ)**, nhãn 1 (lớp xanh lá), hay nhãn 2 (lớp xanh dương).

Ta muốn đầu ra của mô hình **dự đoán xác suất** điểm dữ liệu  $x = (x_1, x_2)$  thuộc về **lớp đỏ (nhãn 0)**, lớp xanh lá (nhãn 1), và lớp xanh dương (nhãn 2) là bao nhiêu.



Có thể sử dụng Hồi quy logistic không?

- Đầu ra của mô hình hồi quy logistic là một giá trị xác suất  $a \in (0,1)$  nên phù hợp với bài toán phân lớp nhị phân có hai nhãn  $y \in \{0,1\}$  nhưng bài toán trên có 3 nhãn  $y \in \{0,1,2\}$ .

# Bài toán phân lớp


Ta muốn đầu ra của mô hình **dự đoán xác suất** điểm dữ liệu  $x = (x_1, x_2)$  thuộc về **lớp đỏ (nhãn 0)**, **lớp xanh lá (nhãn 1)**, **và** **lớp xanh dương (nhãn 2)** là bao nhiêu.

Đầu ra của hồi quy logistic là  $a \in (0,1)$  không phù hợp với trường hợp có nhiều hơn 2 nhãn, ví dụ  $y \in \{0,1,2\}$ .

**Giải pháp:**

Biểu diễn nhãn mỗi điểm dữ liệu thành **one-hot vector**:

$$\text{Đỏ } 0 \sim \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \text{ Xanh lá } 1 \sim \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \text{ Xanh dương } 2 \sim \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$



**Câu hỏi:** Có thể sử dụng 3 mô hình hồi quy logistic độc lập, dự đoán xác suất mỗi lớp  $a_1, a_2, a_3 \in (0,1)$ ?



# Bài toán phân lớp


Ta muốn đầu ra của mô hình **dự đoán xác suất** điểm dữ liệu  $x = (x_1, x_2)$  thuộc về **lớp đỏ (nhãn 0)**, **lớp xanh lá (nhãn 1)**, **và** **lớp xanh dương (nhãn 2)** là bao nhiêu.

Sử dụng 3 mô hình hồi quy logistic độc lập. Mỗi mô hình hồi quy logistic có đầu ra là:

$$a_1 = \sigma(z_1) = \frac{1}{1+e^{-z_1}} \text{ với } z_1 = w_{1,1}x_1 + w_{1,2}x_2 + b_1$$

$$a_2 = \sigma(z_2) = \frac{1}{1+e^{-z_2}} \text{ với } z_2 = w_{2,1}x_1 + w_{2,2}x_2 + b_2$$

$$a_3 = \sigma(z_3) = \frac{1}{1+e^{-z_3}} \text{ với } z_3 = w_{3,1}x_1 + w_{3,2}x_2 + b_3$$



Vấn đề của phương pháp trên?

Mỗi mô hình hồi quy logistic dự đoán xác suất mỗi lớp  $a_1, a_2, a_3 \in (0,1)$  một cách độc lập  $\rightarrow$  Ta không thể ràng buộc  $a_1 + a_2 + a_3 = 1$ .



# Bài toán phân lớp

Ta muốn đầu ra của mô hình **dự đoán xác suất** điểm dữ liệu  $x = (x_1, x_2)$  thuộc về **lớp đỏ (nhãn 0)**, **lớp xanh lá (nhãn 1)**, **và** **lớp xanh dương (nhãn 2)** là bao nhiêu.

Không thể ràng buộc  $a_1 + a_2 + a_3 = 1$  với:

$$a_1 = \sigma(z_1) = \frac{1}{1+e^{-z_1}} \text{ với } z_1 = w_{1,1}x_1 + w_{1,2}x_2 + b_1$$


$$a_2 = \sigma(z_2) = \frac{1}{1+e^{-z_2}} \text{ với } z_2 = w_{2,1}x_1 + w_{2,2}x_2 + b_2$$

$$a_3 = \sigma(z_3) = \frac{1}{1+e^{-z_3}} \text{ với } z_3 = w_{3,1}x_1 + w_{3,2}x_2 + b_3$$

**Giải pháp:** Thay vì sử dụng hàm logistic sigmoid trên từng  $z_i$ , ta sử dụng hàm softmax trên đồng thời tất cả các giá trị  $z_i$  với  $(a_1, a_2, a_3) = \text{softmax}(z_1, z_2, z_3)$ .

$$a_1 = \frac{e^{z_1}}{e^{z_1} + e^{z_2} + e^{z_3}}, \quad a_2 = \frac{e^{z_2}}{e^{z_1} + e^{z_2} + e^{z_3}}, \quad a_3 = \frac{e^{z_3}}{e^{z_1} + e^{z_2} + e^{z_3}}$$



Ta có thể ràng buộc  $a_1 + a_2 + a_3 = 1$ .





# Hồi quy softmax (softmax regression)

Ta muốn đầu ra của mô hình **dự đoán xác suất** điểm dữ liệu  $x = (x_1, x_2)$  thuộc về lớp đỏ (nhãn 0), lớp xanh lá (nhãn 1), và lớp xanh dương (nhãn 2) là bao nhiêu.



Mô hình hồi quy softmax có các tham số là:

$$W = \begin{bmatrix} w_{1,1} & w_{1,2} \\ w_{2,1} & w_{2,2} \\ w_{3,1} & w_{3,2} \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

Với mỗi điểm dữ liệu  $x = (x_1, x_2)$ , ta thực hiện dự đoán:


$$\mathbf{z} = W\mathbf{x} + \mathbf{b}$$

$$\mathbf{a} = \text{softmax}(\mathbf{z})$$



# Hồi quy softmax (softmax regression)

Ta muốn đầu ra của mô hình **dự đoán xác suất** điểm dữ liệu  $x = (x_1, x_2)$  thuộc về lớp đỏ (nhãn 0), lớp xanh lá (nhãn 1), và lớp xanh dương (nhãn 2) là bao nhiêu.



```
W = np.array([[ 0.31, 3.95],
              [ 7.07, -0.23],
              [-6.27, -2.35]])
```

```
b = np.array([[ 1.2 ],
              [ 2.93],
              [-4.14 ]])
```


```
def forward(W, b, x):
    z = np.matmul(W, x) + b
    a = softmax(z)
    return z, a
```

```
# X[0,:] has the shape (1,2)           [-0.1 1.4]
# reshape from (1,2) --> (2,1)          [ 6.699 1.901 -6.803]
x = X[0,:].reshape(2,1)                [0.992 0.008 0. ]
z, a = forward(W, b, x)                0
```

```
print(x.squeeze())
print(z.squeeze())
print(a.squeeze())
print(y[0])
```







# HÀM MẤT MÁT & TÍNH TOÁN GRADIENT

---

## LOSS FUNCTION & GRADIENT COMPUTATION



# Hồi quy softmax – Hàm mắt mát



Ta cần học giá trị ma trận  $W$  và vector  $\mathbf{b}$  để **phân biệt** tốt các điểm dữ liệu **đỏ**, **xanh lá**, **xanh dương** trong tập dữ liệu huấn luyện.

Giả sử ta có 3 điểm dữ liệu như sau:

$$\mathbf{x}^{(1)} = \begin{bmatrix} -0.1 \\ 1.4 \end{bmatrix}, \quad y^{(1)} = 0, \quad \mathbf{x}^{(2)} = \begin{bmatrix} 1.3 \\ 0.9 \end{bmatrix}, \quad y^{(2)} = 1, \quad \mathbf{x}^{(3)} = \begin{bmatrix} -1.4 \\ -1.1 \end{bmatrix}, \quad y^{(3)} = 2$$



Giả sử ta có một mô hình (một bộ phân lớp – classifier) cho ra dự đoán:

$$\mathbf{y}^{(1)} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{a}^{(1)} = \begin{bmatrix} 0.9 \\ 0.1 \\ 0 \end{bmatrix}, \quad \mathbf{y}^{(2)} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{a}^{(2)} = \begin{bmatrix} 0.1 \\ 0.8 \\ 0.1 \end{bmatrix}, \quad \mathbf{y}^{(3)} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{a}^{(3)} = \begin{bmatrix} 0.1 \\ 0.2 \\ 0.7 \end{bmatrix}$$

Đây có phải là một mô hình tốt? Khả năng mô hình này dự đoán đúng 3 điểm dữ liệu trên có cao?



# Hồi quy softmax – Hàm mắt mát



Ta cần học giá trị ma trận  $W$  và vector  $\mathbf{b}$  để **phân biệt** tốt các điểm dữ liệu **đỏ**, **xanh lá**, **xanh dương** trong tập dữ liệu huấn luyện.



**Ví dụ:** Nếu một điểm dữ liệu có nhãn 1

$\mathbf{y}^{(i)} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$  thì nếu mô hình dự đoán  $\mathbf{a}^{(i)} = \begin{bmatrix} 0.1 \\ 0.8 \\ 0.1 \end{bmatrix}$  sẽ tốt hơn một mô hình khác dự đoán  $\mathbf{a}^{(i)} = \begin{bmatrix} 0.2 \\ 0.6 \\ 0.2 \end{bmatrix}$

Ta muốn mô hình (bộ phân lớp – classifier) trả về dự đoán  $\mathbf{a}$  giống với biểu diễn one-hot vector của nhãn  $\mathbf{y}$  của mỗi điểm dữ liệu.



# Hồi quy softmax – Hàm mắt mát



Khả năng của mô hình với bộ giá trị tham số  $W, b$  dự đoán  $\mathbf{a}^{(i)}$  khớp với nhãn one-hot vector  $\mathbf{y}^{(i)}$  của điểm dữ liệu thứ  $i$  trong tập dữ liệu là:

$$\prod_{j=1}^3 (a_j^{(i)})^{y_j^{(i)}}$$

**Ví dụ:** với điểm dữ liệu có nhãn  $\mathbf{y}^{(i)} = (1,0,0)$  và mô hình dự đoán  $\mathbf{a}^{(i)} = (0.9,0.1,0.0)$ , ta có:

$$\prod_{j=1}^3 (a_j^{(i)})^{y_j^{(i)}} = 0.9^1 \times 0.1^0 \times 0.0^0 = 0.9$$



# Ước lượng hợp lý cực đại – Cross Entropy Loss

- Ta cần học giá trị ma trận  $W$  và vector  $\mathbf{b}$  để **phân biệt** tốt các điểm dữ liệu **đỏ**, **xanh lá**, **xanh dương** trong tập dữ liệu huấn luyện.
- Ta cần tìm giá trị ma trận  $W$  và vector  $\mathbf{b}$  để cực đại hóa khả năng mô hình thực hiện dự đoán  $\mathbf{a}^{(i)}$  khớp với nhãn  $\mathbf{y}^{(i)}$  của tất cả  $N$  điểm dữ liệu trong tập huấn luyện:

$$\begin{aligned}\widehat{W}, \widehat{\mathbf{b}} &= \arg \max_{W, \mathbf{b}} \prod_{i=1}^N \prod_{j=1}^3 \left(a_j^{(i)}\right)^{y_j^{(i)}} \text{ với } \mathbf{a}^{(i)} = \text{softmax}(W\mathbf{x}^{(i)} + \mathbf{b}) \\ &= \arg \max_{W, \mathbf{b}} \log \left( \prod_{i=1}^N \prod_{j=1}^3 \left(a_j^{(i)}\right)^{y_j^{(i)}} \right) = \arg \max_{W, \mathbf{b}} \sum_{i=1}^N \sum_{j=1}^3 \log \left(a_j^{(i)}\right)^{y_j^{(i)}} = \arg \max_{W, \mathbf{b}} \sum_{i=1}^N \sum_{j=1}^3 y_j^{(i)} \log \left(a_j^{(i)}\right) \\ &= \arg \min_{W, \mathbf{b}} - \sum_{i=1}^N \sum_{j=1}^3 y_j^{(i)} \log \left(a_j^{(i)}\right) = \arg \min_{W, \mathbf{b}} \sum_{i=1}^N L(W, \mathbf{b}, \mathbf{x}^{(i)}, \mathbf{y}^{(i)}) = \arg \min_{W, \mathbf{b}} J(W, \mathbf{b})\end{aligned}$$

- Đây là hàm mất mát **Cross Entropy (CE) Loss** - trường hợp tổng quát của hàm Binary Cross Entropy (BCE) Loss trong hồi quy logistic.





# Hồi quy softmax – Cross Entropy Loss

$$\mathbf{z} = W\mathbf{x} + \mathbf{b}$$

$$\mathbf{a} = \text{softmax}(\mathbf{z})$$

Hàm mất mát Cross Entropy (CE) so sánh xác suất dự đoán của mô hình  $\mathbf{a}$  với nhãn của một điểm dữ liệu  $\mathbf{y}$ :





Trong trường hợp tổng quát với  $C$  lớp và  $N$  điểm dữ liệu, hàm Cross Entropy (CE) Loss là:

$$J = -\sum_{i=1}^N \sum_{j=1}^C y_j^{(i)} \log(a_j^{(i)})$$



# Hồi quy softmax – Gradient Descent



Ta cần học giá trị ma trận  $W$  và vector  $b$  để **phân biệt** tốt các điểm dữ liệu **đỏ**, **xanh lá**, **xanh dương** trong tập dữ liệu huấn luyện.


- Khởi tạo với bộ tham số ngẫu nhiên  $W$  và  $b$ .
- Cải thiện chất lượng mô hình bằng cách cập nhật  $W$  và  $b$  qua từng vòng lặp:

$$W = W - \alpha \frac{\partial L}{\partial W}$$

$$b = b - \alpha \frac{\partial L}{\partial b}$$



# Tính toán gradient – Lan truyền ngược



Áp dụng quy tắc dây chuyền (chain rule), ta thực hiện lan truyền ngược để tính đạo hàm của hàm mất mát theo các tham số  $W$  và  $b$  của mô hình. Ví dụ:


$$\frac{\partial L}{\partial w_{2,1}} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_2} \frac{\partial z_2}{\partial w_{2,1}}$$

Vậy ta có:

$$\frac{\partial L}{\partial w_{m,n}} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_m} \frac{\partial z_m}{\partial w_{m,n}}, \quad \frac{\partial L}{\partial b_m} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_m} \frac{\partial z_m}{\partial b_m}$$



# Tính toán gradient



$$\frac{\partial L}{\partial w_{m,n}} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_m} \frac{\partial z_m}{\partial w_{m,n}}, \quad \frac{\partial L}{\partial b_m} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_m} \frac{\partial z_m}{\partial b_m}$$

$$\frac{\partial z_m}{\partial w_{m,n}} = \frac{\partial}{\partial w_{m,n}} (w_{m,1}x_1 + w_{m,2}x_2 + \dots + w_{m,n}x_n + \dots + w_{m,d}x_d + b_m) = x_n$$

$$\frac{\partial z_m}{\partial b_m} = \frac{\partial}{\partial b_m} (w_{m,1}x_1 + w_{m,2}x_2 + \dots + w_{m,n}x_n + \dots + w_{m,d}x_d + b_m) = 1$$


$$\frac{\partial z_1}{\partial w_{1,1}} = x_1, \quad \frac{\partial z_1}{\partial w_{1,2}} = x_2, \quad \frac{\partial z_1}{\partial b_1} = 1$$

$$\frac{\partial z_2}{\partial w_{2,1}} = x_1, \quad \frac{\partial z_2}{\partial w_{2,2}} = x_2, \quad \frac{\partial z_2}{\partial b_2} = 1$$

$$\frac{\partial z_3}{\partial w_{3,1}} = x_1, \quad \frac{\partial z_3}{\partial w_{3,2}} = x_2, \quad \frac{\partial z_3}{\partial b_3} = 1$$



# Tính toán gradient




$$\frac{\partial L}{\partial w_{m,n}} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_m} \frac{\partial z_m}{\partial w_{m,n}}, \quad \frac{\partial L}{\partial b_m} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_m} \frac{\partial z_m}{\partial b_m}$$

$$\frac{\partial L}{\partial a_i} = \frac{\partial}{\partial a_i} \left( - \sum_{j=1}^C y_j \log(a_j) \right) = \frac{\partial}{\partial a_i} (-y_i \log(a_i)) = \frac{-y_i}{a_i}$$

$$\frac{\partial L}{\partial \mathbf{a}} = \begin{bmatrix} \frac{\partial L}{\partial a_1} \\ \frac{\partial L}{\partial a_2} \\ \frac{\partial L}{\partial a_3} \end{bmatrix} = \begin{bmatrix} \frac{-y_1}{a_1} \\ \frac{-y_2}{a_2} \\ \frac{-y_3}{a_3} \end{bmatrix}$$



# Tính toán gradient – Đạo hàm softmax



$$\frac{\partial L}{\partial w_{m,n}} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_m} \frac{\partial z_m}{\partial w_{m,n}}, \quad \frac{\partial L}{\partial b_m} = \sum_{i=1}^3 \frac{\partial L}{\partial a_i} \frac{\partial a_i}{\partial z_m} \frac{\partial z_m}{\partial b_m}$$

$$\frac{\partial a_i}{\partial z_m} = \frac{\partial}{\partial z_m} \left( \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}} \right)$$

Ta có:

$$\frac{d}{dx} \frac{f(x)}{g(x)} = \frac{f'(x)g(x) - g'(x)f(x)}{(g(x))^2}$$

Với  $e^{z_i}$  đóng vai trò  $f(x)$  và  $\sum_{j=1}^C e^{z_j}$  đóng vai trò  $g(x)$ .

Ta có 2 trường hợp  $i = m$  và  $i \neq m$ .



# Tính toán gradient – Đạo hàm softmax

➤ Trường hợp  $i = m$

$$\begin{aligned}\frac{\partial a_i}{\partial z_m} &= \frac{\partial}{\partial z_m} \left( \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}} \right) = \frac{(e^{z_i})' \left( \sum_{j=1}^C e^{z_j} \right) - \left( \sum_{j=1}^C e^{z_j} \right)' e^{z_i}}{\left( \sum_{j=1}^C e^{z_j} \right)^2} \\ &= \frac{e^{z_i} \left( \sum_{j=1}^C e^{z_j} \right) - (e^{z_m}) e^{z_i}}{\left( \sum_{j=1}^C e^{z_j} \right)^2} \\ &= \frac{e^{z_i} \left( \sum_{j=1}^C e^{z_j} - e^{z_m} \right)}{\left( \sum_{j=1}^C e^{z_j} \right)^2} = \frac{e^{z_m} \left( \sum_{j=1}^C e^{z_j} - e^{z_m} \right)}{\left( \sum_{j=1}^C e^{z_j} \right)^2} \\ &= \frac{e^{z_m}}{\sum_{j=1}^C e^{z_j}} \frac{\left( \sum_{j=1}^C e^{z_j} - e^{z_m} \right)}{\sum_{j=1}^C e^{z_j}} = \frac{e^{z_m}}{\sum_{j=1}^C e^{z_j}} \left( \frac{\sum_{j=1}^C e^{z_j}}{\sum_{j=1}^C e^{z_j}} - \frac{e^{z_m}}{\sum_{j=1}^C e^{z_j}} \right) \\ &= a_m (1 - a_m)\end{aligned}$$



# Tính toán gradient – Đạo hàm softmax

➤ Trường hợp  $i \neq m$

$$\begin{aligned}\frac{\partial a_i}{\partial z_m} &= \frac{\partial}{\partial z_m} \left( \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}} \right) = \frac{(e^{z_i})' \left( \sum_{j=1}^C e^{z_j} \right) - \left( \sum_{j=1}^C e^{z_j} \right)' e^{z_i}}{\left( \sum_{j=1}^C e^{z_j} \right)^2} \\ &= \frac{0 - (e^{z_m}) e^{z_i}}{\left( \sum_{j=1}^C e^{z_j} \right)^2} \\ &= \frac{-(e^{z_m}) e^{z_i}}{\left( \sum_{j=1}^C e^{z_j} \right)^2} = \\ &= -\frac{e^{z_m}}{\sum_{j=1}^C e^{z_j}} \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}} \\ &= -a_m a_i\end{aligned}$$




# Tính toán gradient – Đạo hàm softmax

$$\frac{\partial a_i}{\partial z_m} = \begin{cases} a_m(1 - a_m), & \text{nếu } i = m \\ -a_m a_i, & \text{nếu } i \neq m \end{cases}$$

$$\begin{aligned}\frac{\partial \mathbf{a}}{\partial \mathbf{z}} &= \begin{bmatrix} \frac{\partial a_1}{\partial z_1} & \frac{\partial a_2}{\partial z_1} & \frac{\partial a_3}{\partial z_1} \\ \frac{\partial a_1}{\partial z_2} & \frac{\partial a_2}{\partial z_2} & \frac{\partial a_3}{\partial z_2} \\ \frac{\partial a_1}{\partial z_3} & \frac{\partial a_2}{\partial z_3} & \frac{\partial a_3}{\partial z_3} \end{bmatrix} = \begin{bmatrix} a_1(1 - a_1) & a_1(-a_2) & a_1(-a_3) \\ a_2(-a_1) & a_2(1 - a_2) & a_2(-a_3) \\ a_3(-a_1) & a_3(-a_2) & a_3(1 - a_3) \end{bmatrix} \\ &= \begin{bmatrix} a_1 & a_1 & a_1 \\ a_2 & a_2 & a_2 \\ a_3 & a_3 & a_3 \end{bmatrix} \circ \left( \begin{bmatrix} (1 - a_1) & (-a_2) & (-a_3) \\ (-a_1) & (1 - a_2) & 0 \\ (-a_1) & (-a_2) & (1 - a_3) \end{bmatrix} \right) \\ &= \begin{bmatrix} a_1 & a_1 & a_1 \\ a_2 & a_2 & a_2 \\ a_3 & a_3 & a_3 \end{bmatrix} \circ \left( \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} - \begin{bmatrix} a_1 & a_2 & a_3 \\ a_1 & a_2 & a_3 \\ a_1 & a_2 & a_3 \end{bmatrix} \right) \\ &= \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} [1 \quad 1 \quad 1] \circ \left( \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} [a_1 \quad a_2 \quad a_3] \right) = \mathbf{a} \mathbf{1}^T \circ (\mathbf{I} - \mathbf{1} \mathbf{a}^T)\end{aligned}$$



# Tính toán gradient – Lan truyền ngược




$$\frac{\partial L}{\partial W} = \begin{bmatrix} \frac{\partial L}{\partial w_{1,1}} & \frac{\partial L}{\partial w_{1,2}} \\ \frac{\partial L}{\partial w_{2,1}} & \frac{\partial L}{\partial w_{2,2}} \\ \frac{\partial L}{\partial w_{3,1}} & \frac{\partial L}{\partial w_{3,2}} \end{bmatrix} = \begin{bmatrix} \frac{\partial L}{\partial z_1} \frac{\partial z_1}{\partial w_{1,1}} & \frac{\partial L}{\partial z_1} \frac{\partial z_1}{\partial w_{1,2}} \\ \frac{\partial L}{\partial z_2} \frac{\partial z_2}{\partial w_{2,1}} & \frac{\partial L}{\partial z_2} \frac{\partial z_2}{\partial w_{2,2}} \\ \frac{\partial L}{\partial z_3} \frac{\partial z_3}{\partial w_{3,1}} & \frac{\partial L}{\partial z_3} \frac{\partial z_3}{\partial w_{3,2}} \end{bmatrix} = \begin{bmatrix} \frac{\partial L}{\partial z_1} x_1 & \frac{\partial L}{\partial z_1} x_2 \\ \frac{\partial L}{\partial z_2} x_1 & \frac{\partial L}{\partial z_2} x_2 \\ \frac{\partial L}{\partial z_3} x_1 & \frac{\partial L}{\partial z_3} x_2 \end{bmatrix} = \frac{\partial L}{\partial \mathbf{z}} [\mathbf{x}_1 \quad \mathbf{x}_2] = \frac{\partial L}{\partial \mathbf{z}} \mathbf{x}^T$$

$$\frac{\partial L}{\partial \mathbf{b}} = \begin{bmatrix} \frac{\partial L}{\partial b_1} \\ \frac{\partial L}{\partial b_2} \\ \frac{\partial L}{\partial b_3} \end{bmatrix} = \begin{bmatrix} \frac{\partial L}{\partial z_1} \frac{\partial z_1}{\partial b_1} \\ \frac{\partial L}{\partial z_2} \frac{\partial z_2}{\partial b_2} \\ \frac{\partial L}{\partial z_3} \frac{\partial z_3}{\partial b_3} \end{bmatrix} = \begin{bmatrix} \frac{\partial L}{\partial z_1} 1 \\ \frac{\partial L}{\partial z_2} 1 \\ \frac{\partial L}{\partial z_3} 1 \end{bmatrix} = \begin{bmatrix} \frac{\partial L}{\partial z_1} \\ \frac{\partial L}{\partial z_2} \\ \frac{\partial L}{\partial z_3} \end{bmatrix} = \frac{\partial L}{\partial \mathbf{z}}$$



# Tính toán gradient – Lan truyền ngược




$$\frac{\partial L}{\partial \mathbf{z}} = \begin{bmatrix} \frac{\partial L}{\partial z_1} \\ \frac{\partial L}{\partial z_2} \\ \frac{\partial L}{\partial z_3} \end{bmatrix} = \begin{bmatrix} \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial z_1} + \frac{\partial L}{\partial a_2} \frac{\partial a_2}{\partial z_1} + \frac{\partial L}{\partial a_3} \frac{\partial a_3}{\partial z_1} \\ \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial z_2} + \frac{\partial L}{\partial a_2} \frac{\partial a_2}{\partial z_2} + \frac{\partial L}{\partial a_3} \frac{\partial a_3}{\partial z_2} \\ \frac{\partial L}{\partial a_1} \frac{\partial a_1}{\partial z_3} + \frac{\partial L}{\partial a_2} \frac{\partial a_2}{\partial z_3} + \frac{\partial L}{\partial a_3} \frac{\partial a_3}{\partial z_3} \end{bmatrix} = \begin{bmatrix} \frac{\partial a_1}{\partial z_1} & \frac{\partial a_2}{\partial z_1} & \frac{\partial a_3}{\partial z_1} \\ \frac{\partial a_1}{\partial z_2} & \frac{\partial a_2}{\partial z_2} & \frac{\partial a_3}{\partial z_2} \\ \frac{\partial a_1}{\partial z_3} & \frac{\partial a_2}{\partial z_3} & \frac{\partial a_3}{\partial z_3} \end{bmatrix} \begin{bmatrix} \frac{\partial L}{\partial a_1} \\ \frac{\partial L}{\partial a_2} \\ \frac{\partial L}{\partial a_3} \end{bmatrix} = \frac{\partial \mathbf{a}}{\partial \mathbf{z}} \frac{\partial L}{\partial \mathbf{a}}$$

$$\frac{\partial \mathbf{a}}{\partial \mathbf{z}} = \begin{bmatrix} a_1(1-a_1) & a_1(-a_2) & a_1(-a_3) \\ a_2(-a_1) & a_2(1-a_2) & a_2(-a_3) \\ a_3(-a_1) & a_3(-a_2) & a_3(1-a_3) \end{bmatrix}, \quad \frac{\partial L}{\partial \mathbf{a}} = \begin{bmatrix} \frac{-y_1}{a_1} \\ \frac{-y_2}{a_2} \\ \frac{-y_3}{a_3} \end{bmatrix}$$




# Tính toán gradient – Lan truyền ngược



$$\begin{aligned}
 \frac{\partial L}{\partial \mathbf{z}} &= \frac{\partial \mathbf{a}}{\partial \mathbf{z}} \frac{\partial L}{\partial \mathbf{a}} = \begin{bmatrix} a_1(1-a_1) & a_1(-a_2) & a_1(-a_3) \\ a_2(-a_1) & a_2(1-a_2) & a_2(-a_3) \\ a_3(-a_1) & a_3(-a_2) & a_3(1-a_3) \end{bmatrix} \begin{bmatrix} -\frac{y_1}{a_1} \\ -\frac{y_2}{a_2} \\ -\frac{y_3}{a_3} \end{bmatrix} \\
 &= \begin{bmatrix} -y_1(1-a_1) + y_2a_1 + y_3a_1 \\ y_1a_2 - y_2(1-a_2) + y_3a_2 \\ y_1a_3 + y_2a_3 - y_3(1-a_3) \end{bmatrix} = \begin{bmatrix} (a_1-1) & a_1 & a_1 \\ a_2 & (a_2-1) & a_2 \\ a_3 & a_3 & (a_3-1) \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} \\
 &= \left( \begin{bmatrix} a_1 \\ a_2 \\ a_3 \end{bmatrix} [1 \quad 1 \quad 1] - \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \right) \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = (\mathbf{a}\mathbf{1}^T - \mathbf{I})\mathbf{y} = \mathbf{a}\mathbf{1}^T\mathbf{y} - \mathbf{I}\mathbf{y} = \mathbf{a} - \mathbf{y}
 \end{aligned}$$



# Tính toán gradient – Lan truyền ngược



Gradient của Cross Entropy (CE) Loss của hồi quy softmax (xét trên 1 điểm dữ liệu):

$$\frac{\partial L}{\partial W} = \frac{\partial L}{\partial \mathbf{z}} [x_1 \quad x_2] = \frac{\partial L}{\partial \mathbf{z}} \mathbf{x}^T = (\mathbf{a} - \mathbf{y}) \mathbf{x}^T$$

$$\frac{\partial L}{\partial \mathbf{b}} = \frac{\partial L}{\partial \mathbf{z}} = (\mathbf{a} - \mathbf{y})$$

Gradient (xét trên cả tập dữ liệu):

$$\frac{\partial J}{\partial W} = \sum_{i=1}^N (\mathbf{a}^{(i)} - \mathbf{y}^{(i)}) \mathbf{x}^{(i)T}, \quad \frac{\partial J}{\partial \mathbf{b}} = \sum_{i=1}^N (\mathbf{a}^{(i)} - \mathbf{y}^{(i)})$$







# Gradient Descent

```
learning_rate = 2.0
num_epochs = 40
def compute_gradient(x, y, z, a):
    dz = a - y
    dW = np.matmul(dz, x.T)
    db = dz.copy()
    return dW, db

def gradient_descent(W, b, dW, db, learning_rate):
    W = W - learning_rate * dW
    b = b - learning_rate * db
    return W, b

W = np.random.rand(3,2)
b = np.zeros((3,1))
for i in range(num_epochs):
    dW = np.zeros(W.shape)
    db = np.zeros(b.shape)
    L = 0
    for j in range(X.shape[0]):
        x_j = X[j,:].reshape(2,1)
        y_j = Y[j,:].reshape(3,1)
        z_j, a_j = forward(W, b, x_j)
        loss_j = compute_loss(y_j, z_j)
        dW_j, db_j = compute_gradient(x_j, y_j, z_j, a_j)

        dW += dW_j
        db += db_j
        L += loss_j
    dW = (1.0/X.shape[0]) * dW
    db = (1.0/X.shape[0]) * db
    L = (1.0/X.shape[0]) * L
    W, b = gradient_descent(W, b, dW, db, learning_rate)
```






# CÀI ĐẶT & PHÂN TÍCH

---

## IMPLEMENTATION & ANALYSIS



# MNIST – Phân loại chữ số viết tay



```
import torch
import torch.nn as nn
import torch.optim as optim
import torch.nn.functional as F
from torch.utils.data import DataLoader
import torchvision.datasets as datasets
import torchvision.transforms as transforms
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')

# Create a Softmax Regression Model
class SoftmaxRegression(nn.Module):
    def __init__(self, input_size, num_classes): # digits 0, 1, 2, ..., 9
        super(SoftmaxRegression, self).__init__()
        self.layer = nn.Linear(in_features=input_size, out_features=num_classes)

    def forward(self, x):
        out = self.layer(x)
        # out = torch.softmax(out)
        return out

# Hyperparameters
input_size = 784 # 28x28 image
num_classes = 10 # 10 digits 0, 1, 2, ...., 9
learning_rate = 0.001
batch_size = 64
num_epochs = 5

model = SoftmaxRegression(input_size=input_size,
                           num_classes=num_classes).to(device)
criterion = nn.CrossEntropyLoss() # In PyTorch, Softmax + NLL
optimizer = optim.SGD(model.parameters(), lr=learning_rate)
```



# MNIST – Phân loại chữ số viết tay

```
# Load the dataset to our Google Drive
train_dataset = datasets.MNIST(root='/content/drive/MyDrive/datasets/mnist',
                               train=True, transform=transforms.ToTensor(), download=True)
test_dataset = datasets.MNIST(root='/content/drive/MyDrive/datasets/mnist',
                             train=False, transform=transforms.ToTensor(), download=True)
train_loader = DataLoader(dataset=train_dataset, batch_size=batch_size, shuffle=True)
test_loader = DataLoader(dataset=test_dataset, batch_size=batch_size, shuffle=False)

# Train our Softmax Regression model
for epoch in range(num_epochs):
    for batch_idx, (data, targets) in enumerate(train_loader):
        data = data.to(device) # Put images to the GPU if GPU is available
        targets = targets.to(device) # Put labels to the GPU if available
        # (64, 1, 28, 28) ----> (64, 784)
        data = data.reshape(data.shape[0], -1)

        # forward pass
        scores = model(data) # Pass one batch of training examples.
        loss = criterion(scores, targets) # Compute the loss function value J

        # backward pass
        optimizer.zero_grad() # Empty the memory
        loss.backward() # Compute the gradient dj/dw
        optimizer.step() # One step of gradient descent

        if (batch_idx+1) % 100 == 0:
            print(f'Epoch {epoch+1}/{num_epochs}, Batch {batch_idx+1}, Loss {loss.item():.2f}'")
```

```
Epoch 1/5, Batch 100, Loss 2.25
Epoch 1/5, Batch 200, Loss 2.10
Epoch 1/5, Batch 300, Loss 2.00
Epoch 1/5, Batch 400, Loss 1.93
Epoch 1/5, Batch 500, Loss 1.85
Epoch 1/5, Batch 600, Loss 1.87
Epoch 1/5, Batch 700, Loss 1.72
Epoch 1/5, Batch 800, Loss 1.64
Epoch 1/5, Batch 900, Loss 1.61
Epoch 2/5, Batch 100, Loss 1.53
.....
Epoch 5/5, Batch 100, Loss 0.97
Epoch 5/5, Batch 200, Loss 0.89
Epoch 5/5, Batch 300, Loss 0.96
Epoch 5/5, Batch 400, Loss 0.90
Epoch 5/5, Batch 500, Loss 0.86
Epoch 5/5, Batch 600, Loss 0.70
Epoch 5/5, Batch 700, Loss 0.89
Epoch 5/5, Batch 800, Loss 0.80
Epoch 5/5, Batch 900, Loss 0.73
```



# MNIST – Phân loại chữ số viết tay

```
# Evaluate the accuracy of the trained model
def check_accuracy(loader, model):
    num_corrects = 0
    num_samples = 0

    model.eval() # Put model into evaluation mode
    with torch.no_grad():
        for data, targets in loader:
            data = data.to(device)
            targets = targets.to(device)
            data = data.reshape(data.shape[0], -1)

            # forward
            scores = model(data) # Scores of a batch ---> in the form of (64, 10)
            #image 1: [s0, s1, s2, ..., s9] ---> s2, 2
            #image 2: [s0, s1, s2, ..., s9] ---> s10, 10
            #.....
            #image 64:[s0, s1, s2, ..., s9] ---> s7, 7
            _, preds = scores.max(1)

            num_corrects += (preds == targets).sum()
            num_samples += preds.size(0)

            print(f'We get {num_corrects}/{num_samples} correct. Accuracy = {float(num_corrects)/float(num_samples)*100.0:.2f}')

check_accuracy(test_loader, model)
We get 8477/10000 correct. Accuracy = 84.77
```

```
import matplotlib.pyplot as plt
image, label = test_dataset[1802]
plt.imshow(image.squeeze(), cmap='gray')

0
5
10
15
20
25
0 5 10 15 20 25

image = image.to(device) # Put the image to the GPU if available
image = image.reshape(image.shape[0], -1) # Reshape the tensor

score = model(image)
print(score)
_, preds = score.max(1)
print(f'Our prediction is {preds.item()}')
tensor([[-0.6124, -1.3164, 2.3769, -1.1956, -0.4008, -1.1456,
0.4172, 0.2381, 1.4189, -0.6130]], device='cuda:0',
grad_fn=<AddmmBackward0>)
Our prediction is 2

torch.nn.functional.softmax(score, dim=1)
tensor([[0.0267, 0.0132, 0.5298, 0.0149, 0.0329, 0.0156,
0.0746, 0.0624, 0.2032, 0.0266]], device='cuda:0',
grad_fn=<SoftmaxBackward0>)
```



# MNIST – Phân loại chữ số viết tay

```
# Evaluate the accuracy of the trained model
def check_accuracy(loader, model):
    num_corrects = 0
    num_samples = 0

    model.eval() # Put model into evaluation mode
    with torch.no_grad():
        for data, targets in loader:
            data = data.to(device)
            targets = targets.to(device)
            data = data.reshape(data.shape[0], -1)


            # forward
            scores = model(data) # Scores of a batch ---> (64, 10)
            #image 1: [s0, s1, s2, ..., s9] ---> s2, 2
            #image 2: [s0, s1, s2, ..., s9] ---> s10, 10
            #.....
            #image 64:[s0, s1, s2, ..., s9] ---> s7, 7
            _, preds = scores.max(1)

            num_corrects += (preds == targets).sum()
            num_samples += preds.size(0)

            print(f'We get {num_corrects}/{num_samples} correct. Accuracy = {float(num_corrects)/float(num_samples)*100.0:.2f}')

check_accuracy(test_loader, model)
We get 8477/10000 correct. Accuracy = 84.77
```

```
import matplotlib.pyplot as plt
image, label = test_dataset[1100]
plt.imshow(image.squeeze(), cmap='gray')

  
image = image.to(device) # Put the image to the GPU if available  
image = image.reshape(image.shape[0], -1) # Reshape the tensor  
  
score = model(image)  
print(score)  
_, preds = score.max(1)  
print(f'Our prediction is {preds.item()}')  
tensor([-1.9898, 1.4574, 0.1530, -0.2754, -0.8373, 0.2092,  
1.7860, -0.9584, 0.6460, -0.1126], device='cuda:0',  
grad_fn=<AddmmBackward0>)  
Our prediction is 6  
  
torch.nn.functional.softmax(score, dim=1)  
tensor([0.0080, 0.2501, 0.0679, 0.0442, 0.0252, 0.0718,  
0.3474, 0.0223, 0.1111, 0.0520], device='cuda:0',  
grad_fn=<SoftmaxBackward0>)
```



# MNIST – Phân loại chữ số viết tay

```
# Evaluate the accuracy of the trained model
def check_accuracy(loader, model):
    num_corrects = 0
    num_samples = 0

    model.eval() # Put model into evaluation mode
    with torch.no_grad():
        for data, targets in loader:
            data = data.to(device)
            targets = targets.to(device)
            data = data.reshape(data.shape[0], -1)


            # forward
            scores = model(data) # Scores of a batch ---> (64, 10)
            #image 1: [s0, s1, s2, ..., s9] ---> s2, 2
            #image 2: [s0, s1, s2, ..., s9] ---> s10, 10
            #.....
            #image 64:[s0, s1, s2, ...., s9] ---> s7, 7
            _, preds = scores.max(1)

            num_corrects += (preds == targets).sum()
            num_samples += preds.size(0)

            print(f'We get {num_corrects}/{num_samples} correct. Accuracy = {float(num_corrects)/float(num_samples)*100.0:.2f}')

check_accuracy(test_loader, model)
We get 8477/10000 correct. Accuracy = 84.77
```

```
import matplotlib.pyplot as plt
image, label = test_dataset[217]
plt.imshow(image.squeeze(), cmap='gray')



  
image = image.to(device) # Put the image to the GPU if available  
image = image.reshape(image.shape[0], -1) # Reshape the tensor  
  
score = model(image)  
print(score)  
_, preds = score.max(1)  
print(f'Our prediction is {preds.item()}')  
tensor([[ 0.0747,  0.5930, -0.2984, -0.2330, -0.0943,  1.5958,  
        0.3566, -1.4400,  0.8870, -0.9277]], device='cuda:0',  
grad_fn=<AddmmBackward0>)  
Our prediction is 5  
  
torch.nn.functional.softmax(score, dim=1)  
tensor([[ 0.0730,  0.1227,  0.0503,  0.0537,  0.0617,  0.3343,  
        0.0968,  0.0161,  0.1646,  0.0268]], device='cuda:0',  
grad_fn=<SoftmaxBackward0>)
```

# Phân tích tham số softmax regression

```
model.state_dict()
OrderedDict([
    ('layer.weight',
        tensor([[ 0.0349, -0.0092,  0.0314, ...,  0.0069,  0.0223, -0.0041],
               [ 0.0033,  0.0243, -0.0173, ..., -0.0064, -0.0092,  0.0318],
               [ 0.0033, -0.0335,  0.0165, ...,  0.0218, -0.0354,  0.0228],
               ...,
               [ 0.0270, -0.0133,  0.0106, ...,  0.0226, -0.0202, -0.0300],
               [-0.0277,  0.0045,  0.0304, ...,  0.0312, -0.0137, -0.0322],
               [-0.0027,  0.0342,  0.0262, ..., -0.0110,  0.0317,  0.0154]], device='cuda:0')),
    ('layer.bias',
        tensor([-0.0714,  0.0465, -0.0165,  0.0134, -0.0157,  0.0391, -0.0322,  0.0303, -0.0566, -0.0136], device='cuda:0'))])

```

```
weight_digit_0 = model.state_dict()['layer.weight'][0]
weight_matrix = weight_digit_0.reshape(28, 28).cpu().numpy()
plt.imshow(weight_matrix, cmap='gray')
```



$$\begin{matrix} X_1 & X_2 & X_3 & \dots & X_{28} \\ X_{29} & X_{30} & X_{31} & & X_{56} \\ X_{57} & X_{58} & X_{59} & & X_{84} \\ \vdots & & & \ddots & \\ X_{757} & X_{758} & X_{759} & & X_{784} \end{matrix}$$

